Veille Technologique — Hardware & Physique pour l'IA

Date : 30 septembre 2026

---

1. GPU et Accélérateurs — L'Ère de la Spécialisation

AMD MI400 : CDNA 5 officiellement lancé — 432 Go HBM4, 19,6 TB/s

Après l'annonce des MI350X/MI355X (CDNA 4) couverte la semaine dernière, AMD a franchi un cap supplémentaire. La gamme **Instinct MI400 (CDNA 5)** a été officiellement lancée lors de la conférence **AMD AAI 2026 (fin juillet)**. La famille comprend trois accélérateurs : **MI430X, MI440X et MI455X**, formant un spectre allant de l'inférence efficace à l'entraînement de frontier AI.

Points techniques clés de la MI400 :

- **432 Go de mémoire HBM4** (configuration maximale)
- **Bande passante mémoire : 19,6 TB/s** — un record absolu pour un accélérateur commercial
- Architecture **CDNA 5**, procédé avancé 3nm chiplets
- Intégration dans le rack scale **Helios** d'AMD
- Positionnement explicite **contre le Vera Rubin de NVIDIA**

AMD a aussi présenté les détails de la MI400 à **Hot Chips 2026 (août)**. ServeTheHome documente la conception avancée des chiplets et l'intégration système. L'enjeu reste le même : capter des parts de marché sur un segment où NVIDIA détient encore plus de 80%.

Sources : AMD AAI 2026 Newsroom · Tom's Hardware MI430X/MI440X/MI455X · TechPowerUp · ServeTheHome Hot Chips

---

NVIDIA Feynman : Confirmation TSMC A16 (1,6nm) pour 2028

Alors que la Vera Rubin est en production pleine cadence, NVIDIA a confirmé cette semaine de nouveaux détails sur son architecture **Feynman**, prévue pour **2028**. L'information majeure : Feynman sera fabriqué sur le procédé **TSMC A16 (1,6nm)**, le premier procédé de TSMC à intégrer des **backside power rails** (réseau d'alimentation en face arrière).

Feuille de route NVIDIA confirmée :

- **Rubin** (R100) — en production, 2026 (NVL72, 1,5 ExaFLOPS FP4)
- **Rubin Ultra** — 2027, avec Co-Packaged Optics (CPO)
- **Feynman** — 2028, TSMC A16 (1,6nm), architecture radicalement repensée
- **NVL1152** — rack scale à 1 152 GPU, annoncé à GTC 2026 en mars

L'architecture Feynman représentera le passage de NVIDIA aux procédés sub-2nm de production de masse. Le backside power delivery network (BSPDN) d'A16 permettra d'augmenter significativement la densité de transistors et de réduire la chute de tension (IR drop) qui limitait les fréquences à partir de 3nm.

Sources : TweakTown Feynman A16 · Roadmap VRLA Tech · HPCwire GTC 2026 NVL1152

Le Front de l'Inférence : AMD-Cerebras vs NVIDIA-Groq

L'un des développements structurants des derniers mois est la **recomposition du marché de l'inférence IA**, distinct de l'entraînement dominé par NVIDIA. Deux coalitions se forment :

Coalition 1 — NVIDIA/Groq :
NVIDIA a acquis **Groq** (fabricant des LPU, Language Processing Units, optimisés inférence ultra-rapide). Cette alliance consolide la position de NVIDIA sur les deux segments : formation (GPU) + inférence (LPU).

Coalition 2 — AMD/Cerebras :
En juillet 2026, AMD a annoncé un **partenariat stratégique avec Cerebras** (fabricant des WSE — Wafer-Scale Engine, la plus grande puce au monde). L'alliance cible l'**inférence à ultra-faible latence et haut débit** pour les LLMs. Data Center Dynamics et The Register confirment que cette alliance est positionnée explicitement comme une réponse aux LPU de Groq.

Fait notable : OpenAI a exprimé son mécontentement vis-à-vis des GPU NVIDIA pour l'inférence (TrendForce, février 2026), signalant que le marché de l'inférence pourrait se fragmenter davantage que celui de l'entraînement. Cerebras est par ailleurs en cours d'**introduction en bourse (IPO 2026)**, selon Morningstar, ce qui lui donne une capitalisation publique et un profil investisseur élevé.

Sources : AMD-Cerebras partenariat — Data Center Dynamics · AMD vs Groq — The Register · OpenAI insatisfait NVIDIA — TrendForce · Cerebras IPO — Morningstar

---

Intel : Gaudi 3 en déploiement, Crescent Island en attente

Intel se bat sur plusieurs fronts. Le **Gaudi 3** (accélérateur IA précédente génération) continue d'être déployé par AWS/IBM Cloud comme alternative économique aux H100 de NVIDIA (Tom's Hardware, IBM Cloud). Sa valeur principale reste le prix : moins cher à louer que les GPU NVIDIA pour certains workloads d'inférence standard.

Du côté de **Crescent Island** (Xe3P), le retard confirmé (rapport du 23/09) se confirme. Aucune date de livraison précise n'a été annoncée publiquement cette semaine. Intel cherche à repositionner sa stratégie puces IA après des difficultés opérationnelles persistantes.

---

2. Mémoire : HBM4 — La Guerre des Parts de Marché

SK Hynix consolide sa domination, Micron dépasse Samsung

Le paysage HBM4 s'est redistribué significativement en septembre 2026 :

- **SK Hynix : 62% du marché HBM global** (Astutegroup) — position dominante
- **Micron a dépassé Samsung** en part de marché HBM pour la première fois (Astutegroup)
- **Samsung** perd du terrain, notamment à cause de difficultés de rendement HBM4 (Semiwiki)
- Les trois acteurs se battent pour **les contrats de fourniture HBM4 16-Hi de NVIDIA** (TweakTown)

La configuration **16-Hi** (16 couches empilées vs 12-Hi standard) est le prochain palier pour doubler la capacité mémoire par stack. SK Hynix vise à fournir environ deux tiers des besoins de NVIDIA en HBM4 selon TrendForce.

Contexte fabrication :

- Samsung et SK Hynix **accélèrent leur production HBM** (Sammy Fans, 14 sept. 2026)
- TSMC augmente sa capacité CoWoS (Chip on Wafer on Substrate) pour répondre à la demande d'intégration HBM+GPU

Sources : SK Hynix 62% marché HBM — Astutegroup · 16-Hi HBM4 NVIDIA — TweakTown · Samsung délai HBM4 — Semiwiki

---

3. Lithographie et Fabrication : TSMC 2nm en Expansion Massive

TSMC hausse la production 2nm de 70%, cible 100 000 wafers/mois

La nouvelle la plus marquante du front fabrication cette semaine vient de **TSMC** qui a annoncé mi-septembre une **hausse de 70% de sa production 2nm** (procédé N2) pour répondre à la demande explosive des puces IA. L'objectif : atteindre **100 000 wafers par mois** d'ici la fin 2026 (WCCFtech).

Détails techniques N2 :

- Première génération de transistors **GAA (Gate-All-Around / Nanosheet)** en production de masse chez TSMC
- **15% de gain de performance** à puissance iso par rapport au N3E
- Premiers clients : Apple (A20), et plusieurs acteurs IA pour puces dédiées
- TSMC expansion simultanée des nœuds **2nm ET 3nm** (Sammy Fans, 14 sept. 2026)

L'expansion du 2nm est critique pour la prochaine génération d'accélérateurs IA attendue en 2027 (AMD MI500, successeur Rubin Ultra). La montée en cadence de production est considérée comme le facteur limitant n°1 de l'industrie IA hardware.

Le procédé **A16 (1,6nm / 1,6A)**, qui équipera le Feynman de NVIDIA en 2028, intègre les **backside power rails** combinées aux transistors GAA, représentant la prochaine rupture de fabrication.

Sources : TSMC 2nm production +70% — Benzinga · TSMC 100k wafers milestone — WCCFtech · Expansion 2nm et 3nm — Sammy Fans

---

4. Calcul Photonique et Neuromorphique : La Recherche s'Accélère

Chips photoniques neuromorphiques : convergence lumière + neurones artificiels

La semaine a vu la publication de plusieurs travaux académiques importants à la jonction du **calcul photonique** et du **calcul neuromorphique** :

- **Advanced Materials (Wiley)** publie une revue sur les puces photoniques neuromorphiques intégrées pour l'accélération IA, couvrant les architectures d'apprentissage en temps réel dans les systèmes de neurones à impulsions (spiking neural networks).
- **Optica / OSA** annonce que des **puces photoniques avancent l'apprentissage en temps réel** dans des systèmes de réseaux de neurones à impulsions (septembre 2026), via des modes photon-matière (polaritons) qui permettent la propagation et le traitement des signaux à la vitesse de la lumière.
- **Science Daily** documente une percée utilisant des **particules lumière-matière** (polaritons) pour le calcul neuromorphique, potentiellement plus efficaces énergétiquement que les approches électroniques classiques.
- Le **Chips journal (MDPI)** publie une revue de l'état de l'art du calcul neuromorphique photonique on-chip.

L'analyse de **PatSnap** cartographie le panorama des brevets photoniques-neuromorphiques en 2026 : 3 pôles géographiques dominent (USA, Chine, Europe), avec une accélération des dépôts depuis 2023. Les applications cibles en IA : reconnaissance de formes ultra-rapide, inférence à la périphérie (edge), télécommunications IA.

Lightmatter reste l'acteur commercial le plus avancé, avec son approche de co-packaging de puces photoniques et électroniques. OLIX (couvert semaine du 23/09) continue de lever des fonds.

Sources : Photonic neuromorphic integré — Advanced Materials/Wiley · Optica spiking neural · Polaritons — Science Daily · Paysage brevets 2026 — PatSnap · Lightmatter — nouveau type d'ordinateur

---

5. Quantique : Convergence Accélérée avec l'IA

IBM vs Google vs IonQ : la course à la tolérance aux pannes

Suite à l'annonce d'IBM de 10 milliards de dollars pour le quantique (juin 2026), les analyses comparatives se multiplient. L'état des forces en présence en septembre 2026 :

Acteur	Approche	Qubits (2026)	Objectif majeur
IBM	Superconducteurs	~2 000 qubits (Eagle/Heron)	Correction d'erreurs, 2029
Google	Superconducteurs	~1 000+ qubits (Willow+)	Avantage quantique pratique
IonQ	Ions piégés	~1 000 "algorithmic qubits"	Fidélité élevée
Quantinuum	Ions piégés hybrides	Fidélité record	Applications chimie/finance

L'intersection **quantique + IA** se structure autour de trois cas d'usage réalistes à horizon 5 ans :

1. **Simulation moléculaire** pour découverte de matériaux (batteries, catalyseurs, semi-conducteurs)
2. **Optimisation combinatoire** (routage, logistique, VLSI design)
3. **Algèbre linéaire creuse** pour certains problèmes ML spécifiques

L'entraînement de LLMs par calcul quantique reste hors horizon. Le quantique sert l'IA comme **outil de conception** (simuler de nouveaux matériaux pour puces) plus que comme **substrat d'exécution** à court terme.

Sources : 5 percées quantiques 2026 — BQPsim · Comparatif hardware quantique — Quantum AI Report · Convergence quantique-IA 2026 — AI Driven Dev

---

6. Énergie et Infrastructure : De la Fusion aux Réacteurs Modulaires

Fusion nucléaire pour data centers IA : du rêve au calcul réel

Une contribution académique notable est apparue cette semaine sur **arXiv** : *"Nuclear fusion for AI: A pathway to power data centers sustainably"* — une analyse quantitative de la faisabilité d'alimenter les data centers IA par fusion nucléaire. L'article modélise les besoins énergétiques des clusters d'IA à horizon 2030-2040 et les projections de production fusion.

Contexte énergétique IA :

- Les data centers IA consommeront **estimé 1 000 TWh/an** d'ici 2030 selon plusieurs projections (WEF, janvier 2026)
- La fusion commerciale (Commonwealth Fusion Systems, TAE Technologies, Helion) vise des premières centrales **2035-2040**
- L'article arxiv conclut que la fusion peut être une **solution structurelle à long terme** mais ne résoudra pas la crise énergétique IA avant 2035 minimum

L'analyse du **Geekwire** (2026) sur la course pour alimenter les data centers IA en fusion révèle que plusieurs startups de fusion ont signé des **letters of intent** avec des hyperscalers, mais que les détours techniques (confinement, durée plasma) restent les défis majeurs. Le **WEF** a publié en janvier 2026 une analyse positive de la synergie fusion+IA.

Sources : Fusion pour data centers IA — arXiv · Course fusion IA — Geekwire · WEF Fusion+IA — World Economic Forum

SMR (Small Modular Reactors) : Rapport annuel 2026 et nuances

Le **State of SMR 2026** (SMR Intelligence Annual Report) vient de paraître, offrant un bilan complet de l'industrie des petits réacteurs modulaires. Les grandes tendances :

- **Big Tech investit massivement** : Microsoft, Google, Amazon, Meta ont tous signé des accords d'achat d'électricité SMR
- **Délais réels** : la plupart des projets SMR ciblant les data centers ne démarreront pas avant **2030-2033**
- **Bulletin of the Atomic Scientists (juillet 2026)** nuance fortement le "PR hype" : la réalité des délais de certification nucléaire et de construction rend le discours de Big Tech prématuré

Pendant l'attente des SMR, la stratégie réelle des hyperscalers est de **se brancher sur des réacteurs nucléaires existants** (colocalisation), une option désormais facilitée réglementairement aux États-Unis (The Register, février 2026, couvert semaine précédente).

Sources : State of SMR 2026 — SMR Intel · Big Tech SMR hype nuancé — Bulletin Atomic Scientists · SMR pour cloud — IDTechEx

Refroidissement liquide : Technologie dominante en 2026

Le refroidissement liquide est désormais la norme dans les nouveaux data centers IA, selon Lombard Odier (janvier 2026) et CoolIT Systems. Les trois architectures qui s'imposent en 2026 :

1. **Direct Liquid Cooling (DLC)** : tuyaux d'eau directement en contact avec les cold plates des GPU — le plus répandu
2. **Immersion Cooling** : baignoires de diélectrique où les serveurs baignent — le plus efficace mais coûteux à installer
3. **Rear-door Heat Exchangers** : hybride air/liquide — solution de transition pour data centers existants

Le marché du refroidissement liquide data center devrait atteindre **29,5 milliards de dollars d'ici 2033** selon Fortune Business Insights. Les GPU à 1 000W+ (Rubin, MI400) rendront le refroidissement liquide **obligatoire** dans les nouveaux clusters.

Sources : Liquid cooling dominance 2026 — Lombard Odier · Architectures refroidissement — DataCenters.com · Marché 29,5Mds$ — Fortune Business Insights

---

Synthèse — Points à Surveiller

Domaine	Nouveauté semaine du 30/09	Impact	Maturité
AMD MI400 / CDNA 5	432 Go HBM4, 19,6 TB/s lancé	★★★★★	Maintenant
NVIDIA Feynman / TSMC A16	Confirmé pour 2028, backside power rails	★★★★☆	2028
AMD-Cerebras alliance	Inférence ultra-rapide vs NVIDIA-Groq	★★★★☆	Maintenant
Cerebras IPO	Valorisation publique, financement IA	★★★☆☆	En cours
SK Hynix 62% HBM, Micron > Samsung	Recomposition marché mémoire	★★★★☆	Maintenant
TSMC 2nm +70% production	100k wafers/mois fin 2026	★★★★★	Maintenant
Photonique neuromorphique (papiers)	Convergence light+neurones	★★★☆☆	Recherche
Fusion nucléaire IA (arXiv)	Analyse quantitative viable post-2035	★★☆☆☆	2035+
SMR rapport annuel 2026	Réalité vs PR : délais 2030-2033	★★★☆☆	2030+
Refroidissement liquide	Norme industrielle confirmée	★★★★☆	Maintenant

Tendances structurelles de la semaine

1. La spécialisation de l'inférence crée un duopole parallèle
Le marché se bipolaise : entraînement (NVIDIA dominant) vs inférence (NVIDIA-Groq vs AMD-Cerebras). Cette division n'existait pas en 2024. Les entreprises qui déploient des LLMs en production vont choisir des stacks différentes pour chaque workload.

2. La course mémoire avantage SK Hynix, fragilise Samsung
Pour la première fois, Micron dépasse Samsung dans les parts de marché HBM. Samsung, longtemps incontournable, fait face à des problèmes de rendement HBM4 qui pourraient coûter des contrats NVIDIA majeurs. SK Hynix consolide une position quasi-monopolistique.

3. TSMC 2nm = le goulot d'étranglement stratégique de 2027
La hausse de production 2nm est la décision industrielle la plus importante de la semaine. Tous les accélérateurs IA de prochaine génération (AMD MI500, Rubin Ultra, puces custom

Apple/Google/Amazon) dépendent de cette montée en cadence. Qui obtient les tranches 2nm en priorité détermine qui peut livrer ses clients en 2027.

4. Le calcul photonique sort de la niche académique
Les publications académiques se multiplient sur le neuromorphique photonique, et les startups (OLIX, Lightmatter) lèvent à des valorisations milliardaires. Le paradigme "lumière = calcul" pour l'inférence IA est désormais une thèse d'investissement crédible, même si la commercialisation reste à 3-5 ans.

5. L'énergie : nucléaire existant maintenant, SMR en 2030+, fusion en 2035+
La clarification temporelle est importante : les hyperscalers ne peuvent pas attendre les SMR pour alimenter leurs data centers actuels. La stratégie réelle est de se connecter aux réacteurs existants (colocalisation) immédiatement, et d'attendre les SMR pour les expansions 2030+. La fusion est une option post-2035.

Sources Principales

- AMD AAI 2026 MI400 — AMD Newsroom
- AMD MI430X/MI440X/MI455X — Tom's Hardware
- AMD MI400 vs Vera Rubin — TechPowerUp
- AMD MI400 Hot Chips — ServeTheHome
- NVIDIA Feynman TSMC A16 — TweakTown
- NVIDIA Roadmap 2026-2030 — VRLA Tech
- NVIDIA NVL1152 GTC 2026 — HPCwire
- AMD-Cerebras inférence — Data Center Dynamics
- AMD-Cerebras vs Groq — The Register
- Cerebras IPO 2026 — Morningstar
- OpenAI insatisfait NVIDIA inférence — TrendForce
- SK Hynix 62% marché HBM — Astutegroup
- HBM4 16-Hi NVIDIA — TweakTown
- Samsung délais HBM4 — Semiwiki
- TSMC 2nm +70% — Benzinga
- TSMC 2nm 100k wafers — WCCFtech
- TSMC expansion 2nm+3nm — Sammy Fans
- Photonic neuromorphique integré — Advanced Materials/Wiley
- Chips photoniques spiking neural — Optica
- Polaritons neuromorphique — Science Daily
- Brevets photonique-neuromorphique 2026 — PatSnap
- 5 percées quantiques — BQPsim
- Hardware quantique comparatif — Quantum AI Report

- Fusion nucléaire data centers — arXiv
- Course fusion IA — Geekwire
- Fusion + IA — WEF
- State of SMR 2026 — SMR Intel
- SMR hype vs réalité — Bulletin Atomic Scientists
- Liquid cooling dominance — Lombard Odier
- Architectures refroidissement — DataCenters.com